2 문자열 압축

컴퓨팅 시스템은 문자 데이터를 문자 집합의 이진 코드로 표현한다. 문자열은 문자들의 집합으로서 반복되는 같은 문자나 부분 문자열을 더 적은 수의 비트로 표현해 문자열을 압축한다. 문자열 압축은 비손실 압축 방식을 사용하며, 가장 간단한 비손실 압축 알고리즘으로는 런-렝스(Run-Length) 인코딩, 렘펠-지브(Lempel-Ziv) 인코딩 등이 있다.

문자 집합(character set)
- 사람이 사용하는 문자를 컴퓨터가 이해하는 코드로 표현한 것이다.
- 아스키코드, 유니코드 등이 있다.

1 런-렝스 인코딩

동일한 문자가 연속해서 반복되는 경우, 그것을 반복 문자 개수와 반복 문자의 쌍으로 표현하는 인코딩 알고리즘이다. 알고리즘이 단순하고 반복되는 문자가 길게 나타날수록 압축 효율이 높다.

숫자가 포함되어 문자열의 압축
원래 문자열에 숫자가 포함되어 있는 경우 출현 빈도가 적은 문자를 탈출 문자(예 '*')로 사용해 반복 문자 개수와 구분하여 압축할 수 있다.
예 "AB3AAAA" → "AB3*4A"

▲ 런-렝스 인코딩으로 문자열 압축하기

2 렘펠-지브 인코딩

문자열에 포함된 같은 패턴의 상대적 위치와 패턴의 길이로 문자열을 치환하여 압축하는 방법이다. 떨어져 있는 같은 패턴도 압축이 가능한 것이 장점이며 반복 패턴이 많이 포함된 긴 문자열에서 압축 효율이 높다.

다양한 압축 알고리즘
실제 압축 효율을 높이기 위해서 '런-렝스', '렘펠-지브' 뿐만 아니라, 문자 출현 빈도에 따라 다른 길이의 이진 코드를 할당하는 등 다양한 알고리즘들이 결합, 변형, 확장되어 사용돼요.

▲ 렘펠-지브 인코딩으로 문자열 압축하기