03 기계학습의 모델과 구현

학습 목표
- 지도학습과 비지도학습의 모델별 개념을 이해할 수 있다.
- 기계학습을 활용하여 해결할 수 있는 문제와 그렇지 않은 문제를 구분할 수 있다.
- 기계학습을 활용하여 사회 문제 해결에 적용할 수 있다.

학습 요소 기계학습, 분류, 회귀, 군집화, 문제 해결

1 기계학습의 다양한 모델

기계학습의 다양한 모델 (PDF)

기계학습은 데이터로 학습한 경우에 지도학습과 비지도학습으로 나눈다. 지도학습은 성적이나 온도 예측 등 연속적인 값을 예측하는 회귀 모델과 영상 인식, 스팸 메일 등 몇 가지 범주로 구분하는 분류 모델로 나눌 수 있다. 비지도학습은 비슷한 특징끼리 모으는 군집화와 데이터의 관련성을 찾는 연관 규칙 등이 있다.

1 회귀 모델 지도학습

회귀의 활용 예
- 미래의 강우량 예측
- 운행 거리에 따른 중고차 판매 가격 예측
- 원유 가격 예측
- 시간별 지하철 이용 승객 예측

회귀는 연속적인 수치형 데이터를 예측하는 지도학습 방법이다. 입력값과 결괏값의 관계를 잘 나타내는 함수를 만들고 새로운 값이 입력되면 이 함수를 이용하여 예측하는 방법이다. 이 중에 선형 형태의 함수 모델을 사용하면 선형 회귀라고 한다. 선형 회귀는 광고비 지출에 따른 판매량 예측, 면적에 따른 주택 가격 예측, 거리에 따른 택시비 예측 등에 활용된다.

학습 시간	성적(점수)
10	70
12	76
15	85
20	92
25	93

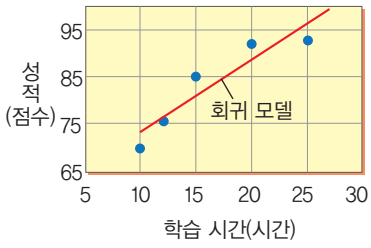

▲ 학습 시간에 따른 성적 예측 회귀 모델

분석 학습 시간에 따른 성적을 예측하려면 좌표에 학습 시간과 성적을 표시하고 두 속성의 관계를 표현하는 직선(빨간색 선, 회귀 모델)을 나타낼 수 있다. 이 직선을 이용하여 30시간을 공부할 때의 성적을 예측할 수 있다.

예를 들면 학습 시간과 수면 시간, 결석 횟수 등 여러 요인을 바탕으로 성적을 예측하는 회귀 모델을 구현할 수 있고, 이 요인들을 활용하여 합격과 불합격을 예측하는 모델도 만들 수 있다.

학습 시간	수면 시간	결석 횟수	성적(점수)
10	8	2	70
8	8	1	85
12	9	0	92
13	8	1	?

학습 시간	수면 시간	결석 횟수	결과
10	8	2	불합격
8	8	1	합격
12	9	0	합격
13	8	1	?

▲ 학습 시간, 수면 시간, 결석 횟수에 따른 성적 예측 회귀 모델 예

선형 회귀의 종류
선형 회귀에는 하나의 특징에 따른 결과를 예측하는 단순 선형 회귀와 두 개 이상의 특징에 따른 결과를 예측하는 다중 선형 회귀가 있다.

2 분류 모델

지도학습

분류는 입력 데이터가 미리 정의된 둘 이상의 범주(클래스) 중 어디에 해당하는지 정하는 것이다. 예를 들어 손으로 쓴 숫자를 10개의 숫자 중 하나로 분류하도록 모델을 학습시킬 수 있다. 이때 특정 데이터의 범주(클래스) 값을 레이블이라고 부른다. 주어진 예시 데이터로 학습된 모델은 클래스를 구분하는 경계를 나타내며, 이 경계를 기준으로 새로운 데이터가 어떤 클래스에 속하는지 판단한다. 분류 모델은 암의 양성 여부, 손 글씨체 숫자 판별, 스팸 메일 분류 등에 활용된다.

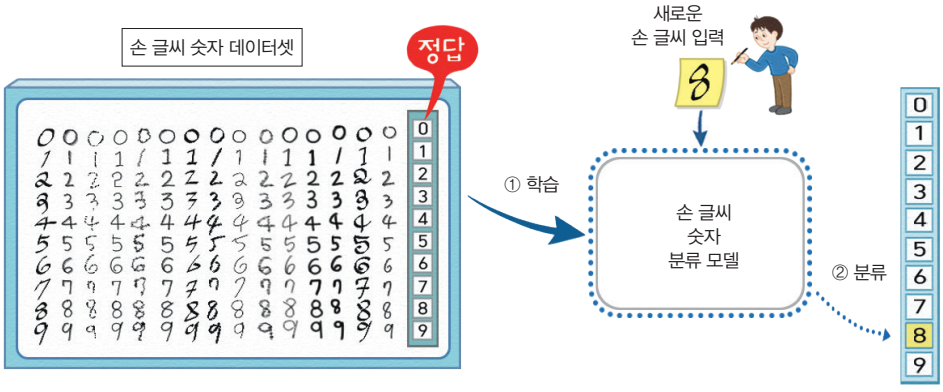

▲ 손 글씨체를 이용한 분류 모델

다양한 손 글씨 숫자 데이터셋(훈련 데이터)를 함께 학습시키면 기계학습은 각 숫자 이미지의 세부 특징을 파악하여 훈련하고, 새로운 손 글씨 이미지(테스트 데이터)가 입력되면 학습된 모델에 대입하여 숫자를 분류할 수 있다.

훈련 데이터
모델의 학습에 사용하는 수많은 데이터를 말한다.

테스트 데이터
학습을 마친 모델의 성능을 평가하기 위해 사용하는 데이터를 말한다.

기계학습의 분류 모델에서 적용하는 알고리즘에는 결정트리, 로지스틱 회귀, k-최근접 이웃, 인공 신경망 등이 있다. 같은 데이터라도 분류 모델 알고리즘에 따라 성능이 다를 수 있으므로 알고리즘의 원리를 이해하고 문제 해결에 가장 적합한 방법을 적용해야 한다.

다양한 분류 알고리즘을 활용하여 지폐의 아래와 위의 여백, 지폐 길이 등의 데이터를 바탕으로 진짜 지폐와 위조지폐를 분류해 보자.

지폐 분류 데이터 출처
https://www.kaggle.com/datasets/alexandrepetit881234/fake-bills

(1) 결정트리

트리 구조 기반의 알고리즘으로 트리의 루트에서부터 각 분기마다 특징에 대한 분류 기준을 만들어서 데이터를 분류하는 방법이다. 이때 분류 기준이 너무 많아 트리가 깊어질수록 예측 성능이 떨어질 수도 있다.

결정트리는 분류 문제나 회귀 문제에 모두 적용할 수 있어요.

결정트리 알고리즘
① 데이터를 가장 잘 분류할 수 있는 특징을 선택한다.
② 선택한 특징의 기준값에 따라 크고 작음을 비교하여 데이터를 하위 그룹으로 나눈다.
③ 분류된 하위 그룹에서 다시 기준값을 정하고 그 기준에 따라 하위 그룹을 나누는 과정을 반복한다.

지폐의 특징인 아래 여백과 위 여백에 따라 진짜 지폐와 위조 지폐를 분류하는 결정트리 모델을 만들 수 있다.

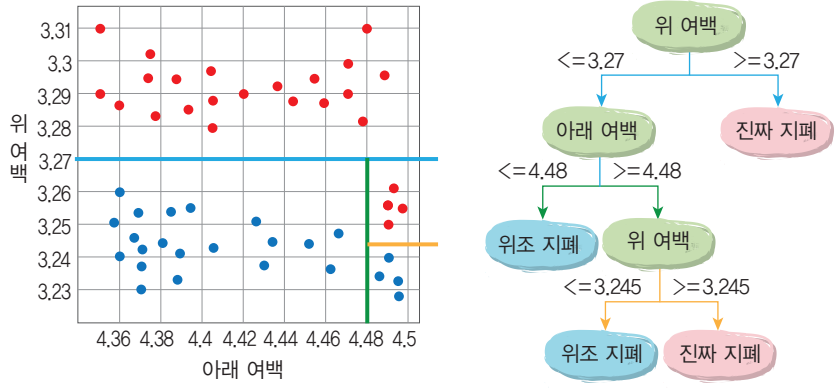

분석
- 진짜 지폐(빨간색 원)와 위조지폐(파란색 원)를 결정트리로 분류하면 x축과 y축에 수평한 직선을 그어 가며 한 클래스에 해당하는 데이터만 남도록 할 수 있다.
- 지폐의 위아래 여백의 길이에 따라 한 가지 클래스로 분류되도록 분류 기준을 찾는 모델이다.

▲ 위조지폐 구분을 위한 결정트리

(2) 로지스틱 회귀

로지스틱 회귀 함수에 의해 데이터가 어떤 클래스에 속할 확률을 0부터 1 사이의 값으로 예측하고, 그 확률에 따라 가능성이 더 높은 클래스로 분류하는 방법이다. 주로 0.5를 기준으로 분류를 수행한다.

지폐의 아래 여백과 위 여백값을 이용하여 진짜 지폐와 위조지폐를 분류하는 로지스틱 회귀 모델을 만들 수 있다.

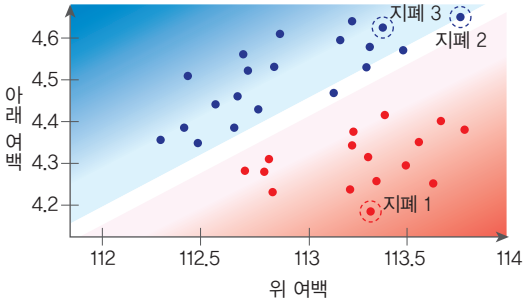

▲ 위조지폐 구분을 위한 로지스틱 회귀

데이터	로지스틱 회귀 결과	분류 결과
지폐 1	0.21	진짜 지폐
지폐 2	0.98	위조지폐
지폐 3	0.82	위조지폐

분석 지폐의 아래위 여백에 따라 지폐의 진위 여부를 알고 싶다면 로지스틱 함수에 입력하여 위조지폐로 분류될 확률에 따라 경계를 그을 수 있다. 이와 같이 경계선으로 분류하는 모델을 선형 분류 모델이라고 하며 로지스틱 회귀가 대표적이다.

로지스틱 회귀는 모델 이름에 '회귀'라는 용어가 있지만 분류에 사용돼요.

로지스틱 회귀 함수의 그래프

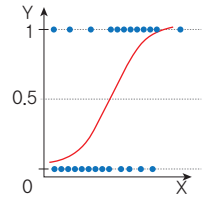

(3) k-최근접 이웃

새로운 데이터가 들어왔을 때, k개의 가까운 이웃 데이터의 클래스를 확인하고 그중 많은 수가 속하는 클래스로 분류하는 방법이며 kNN(k-Nearest Neighbor)이라고도 한다.

kNN 알고리즘
(kNN의 k는 예측 데이터의 가장 가까운 이웃의 수를 뜻한다.)
① 기존 데이터와 예측할 데이터 사이의 거리를 각각 계산한다.
② 거리가 가까운 순서대로 k개의 이웃을 찾는다.
③ k개의 이웃 중 더 많은 수의 이웃이 속해 있는 클래스로 분류한다.

지폐의 아래 여백과 지폐 길이 특징을 이용하여 kNN 알고리즘으로 진짜 지폐와 위조지폐를 분류할 수 있다.

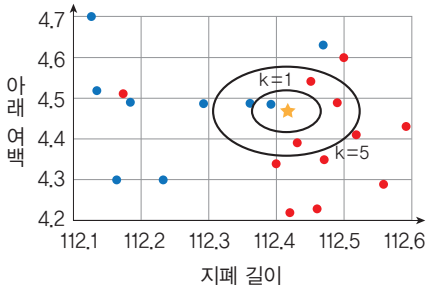

▲ 위조지폐 구분을 위한 k-최근접 이웃

분석
- 빨간 원(진짜 지폐)과 파란 원(위조지폐)의 데이터가 있고, 노란 별 데이터가 속하는 클래스를 알고 싶다면 노란 별과 가장 가까운 이웃 데이터를 확인한다.
- 가장 가까운 k개의 데이터의 클래스를 확인하고 그중 많은 수가 속한 클래스에 새로운 데이터를 속하게 한다.
- k=1이라면 파란 원이 빨간 원보다 많으므로 '위조지폐' 클래스에 속한다고 예측할 수 있고, k=5라면 빨간 원이 더 많으므로 '진짜 지폐' 클래스에 속한다고 예측할 수 있다.

데이터와 예측할 데이터와의 거리를 구하는 방법
- 유클리디안 거리와 맨하튼 거리

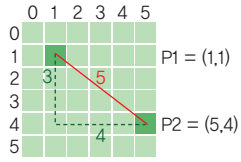

– 유클리디안 거리
$= \sqrt{(5-1)^2+(4-1)^2} = 5$
– 맨하튼 거리
$= |5-1|+|4-1| = 7$

- 거리 기반 알고리즘(최근접 이웃, 로지스틱 회귀)은 모델 생성 전에 데이터 정규화를 수행해야 한다.

(4) 인공 신경망

인공 신경망은 선형 모델의 단점을 해결한 비선형 모델을 만들 수 있어요.

사람의 뇌 신경계가 정보를 처리하는 방식을 모방한 모델이다. 사람의 두뇌가 수많은 뉴런으로 연결되어 있는 것처럼 수많은 노드라고 하는 소자를 연결하여 신호들을 주고받도록 한다. 인공 신경망의 연결이 깊어질수록 더 복잡한 문제를 해결할 수 있으며, 이것을 심층 신경망이라고 한다.

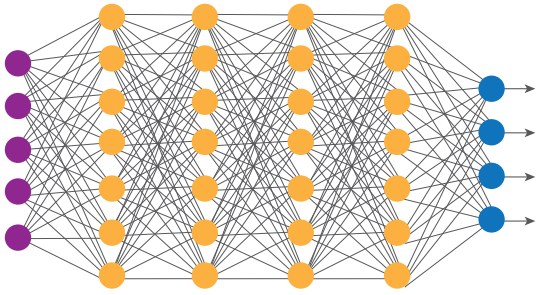

▲ 심층 신경망 모델 구조

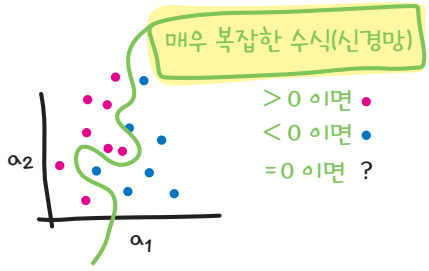

▲ 인공 신경망 모델에 의해 분류된 클래스 영역

3 군집화

비지도학습

분류와 군집화
군집화는 비지도학습이기 때문에 형성된 군집이 맞거나 틀렸다고 할 수 없다. 분류는 대상의 종류를 판별하는 데 목적이 있다면, 군집화는 군집화의 결과로 얻은 정보를 해석하고 활용하는 데 목적이 있다.

군집화는 정답이 없는 데이터의 특징을 분석하여 서로 비슷한 특징을 가진 데이터끼리 그룹화하는 것이다. 이때 같은 군집에 속하는 데이터는 서로 비슷하지만, 다른 군집에 속하는 데이터는 차이가 크게 나도록 나누는 것이 좋다. 데이터들의 유사성은 데이터 간의 거리를 기준으로 측정한다.

유클리디안 거리나 맨하튼 거리 방법을 사용하여 구한다.

군집화는 비슷한 성향의 고객을 그룹화하는 시장 세분화 마케팅이나 비슷한 사진끼리 모아서 관리해 주는 프로그램 등에 활용될 수 있다.

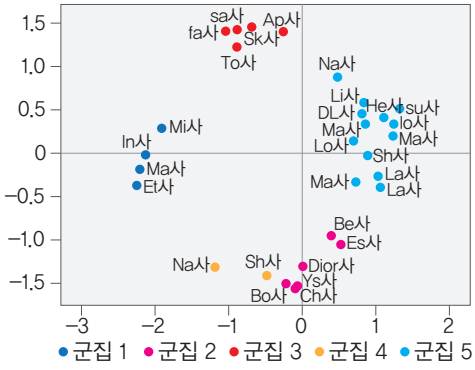

▲ 화장품 브랜드 군집화

분석

화장품 브랜드 군집화 결과

- 군집화 방법: SNS에서 두 개의 브랜드가 함께 언급되는 빈도로 군집화한다.
- 활용: 고객의 인지를 SNS 데이터로 파악하고 비슷하게 인지되는 브랜드를 파악해 볼 수 있다.

대표적인 군집화 알고리즘으로는 k−평균 군집화 알고리즘이 있다.

(1) k-평균 군집화 알고리즘

k-평균 군집화(k-means clustering) 알고리즘은 주어진 데이터를 k개의 군집으로 묶는 비지도학습 방법이다. 몇 개의 군집으로 묶을 것인지 정하고 각 군집의 중심점을 설정한다. 각각의 데이터는 중심점까지의 거리를 측정하여 가장 가까운 중심점에 할당한다. 이후 군집의 중심점은 군집에 속한 데이터들의 평균 위치로 변경되고 군집의 중심이 바뀌지 않을 때까지 반복한다.

군집(cluster)
비슷한 특성을 가진 데이터끼리의 묶음을 말한다.

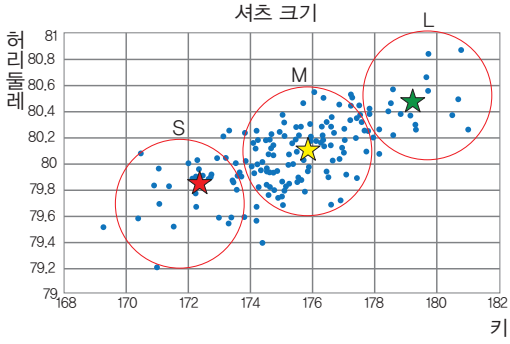

데이터와 중심점까지의 거리
유클리디안 거리나 맨하튼 거리 방법을 사용하여 구한다.

분석 키와 허리둘레에 따라 3가지 크기의 셔츠를 만들려고 한다면 S, M, L과 같이 3개의 군집으로 나눌 수 있다. 초기 중심점은 임의의 위치에 3개가 설정되며 각 데이터는 가장 가까운 군집으로 할당한다. 중심점의 위치가 변경되면서 군집이 새롭게 할당되는 것을 반복한다. 군집 안의 데이터와 중심점 사이의 거리가 가까울수록 군집화의 결과가 좋다고 할 수 있다.

군집의 개수에 따라 성능이 달라질 수 있으므로 적절한 군집의 개수를 정해 주는 것이 좋아요.

▲ 셔츠 크기 군집화

4 연관 규칙

비지도학습

데이터 항목들 간의 연관성을 찾는 것이다. 예를 들면 거래 데이터에서 구매 항목들 사이의 관련성을 분석하여 '만약 우유를 구매하였다면 식빵도 구매할 것이다.'라는 규칙을 발견하는 것이다. 연관 규칙을 이용하여 고객에게 관련 있는 상품을 추천할 수 있고 매장에 상품을 배치하는 데에 활용할 수 있다. 연관 규칙은 도서 추천 시스템 구축이나 상황별 음악을 추천해 주는 서비스 등에 활용된다.

- 음악 추천 서비스: 나와 다른 사람이 같은 음악을 듣거나 멜로디와 템포 등이 유사한 곡을 들으면 두 사람의 음악 취향이 비슷하다고 판단하여 추천한다.
- 도서, 웹툰 추천 서비스: 나와 다른 사람이 같은 콘텐츠를 보거나 제목과 설명, 이미지 등이 유사한 콘텐츠를 보면 취향이 비슷하다고 판단하여 추천한다.

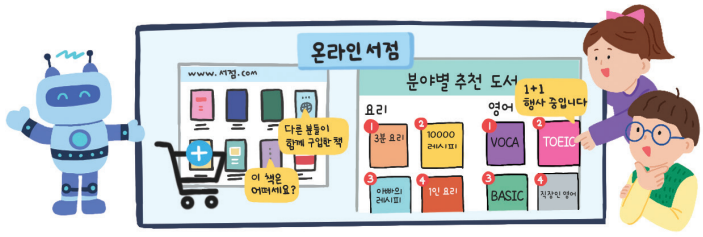

▲ 연관 규칙의 예