2 기계학습의 구현

1 기계학습의 구현 과정

기계학습 구현 과정
(동영상)

기계학습으로 문제를 해결하는 과정은 문제 상황에 따라 생략되거나 반복될 수 있으므로 전체적인 흐름을 이해하며 실제 문제를 해결해야 한다. 우리 생활 주변에서 기계학습이 적용되는 문제를 해결하는 과정은 다음과 같다.

단계 1 문제 정의하기

- 새로운 문제를 발견하고 문제를 명확하게 하는 단계이다.
- 기계학습으로 해결할 수 있는 문제인지 판단한다.

단계 2 데이터 수집 및 전처리하기

Link 58쪽

- 기계학습으로 해결할 수 있도록 필요한 데이터를 수집한다.
- 데이터를 직접 만들거나 측정하여 수집할 수 있고, 공공 기관이나 민간 기관 등의 준비된 데이터셋을 사용할 수도 있다.
- 수집한 데이터의 통계 정보를 확인하거나 학습에 알맞은 핵심 속성을 파악한다.
- 데이터의 결측치나 이상치를 처리하고 학습에 적합한 형태로 가공한다.

단계 3 모델 선정 및 학습하기

- 문제 해결에 적합한 기계학습 유형과 각 유형에 적절한 모델을 선정한다.
- 기계학습의 모델은 분류, 회귀, 군집화 등이 있다.

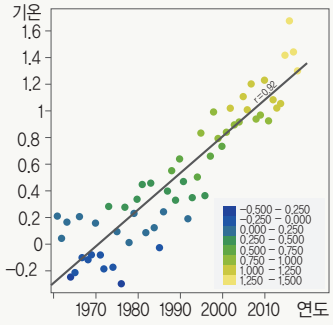

▲ 회귀: 지구 온도 변화 예측하기

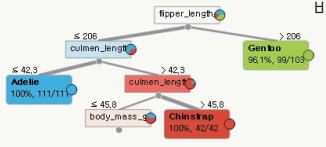

▲ 분류: 펭귄 종 분류하기

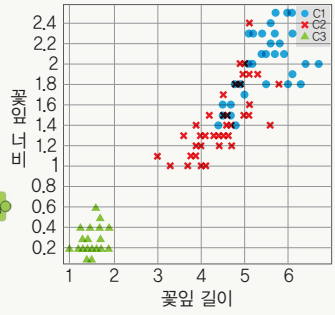

▲ 군집화: 붓꽃 종 군집화하기

- 훈련 데이터를 입력하여 기계학습 모델을 학습시키고, 테스트 데이터로 모델의 성능을 평가한다.
- 모델 학습 과정에서 성능을 높이기 위해 알고리즘, 속성, 설정값 등을 변경할 수 있다.

단계 4 모델 평가하기

모델의 학습 결과를 평가하고 평가 결과를 바탕으로 다른 모델로 변경하거나 같은 모델을 수정하여 성능을 개선한다.

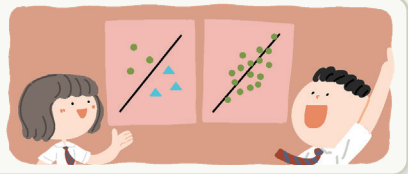

2 기계학습으로 해결할 수 있는 문제

기계학습으로 문제 해결(PDF)

기계학습은 문제 해결을 위한 명확한 규칙과 알고리즘이 없어서 사람이 프로그래밍하기 어려운 문제를 해결하는 데 주로 사용된다. 이를 위하여 대량의 데이터에서 학습을 통하여 규칙을 찾거나 모델을 만들어 활용한다.

예를 들면 실시간으로 주식 시장 데이터를 감지해 이상 신호를 찾아내거나 의료 영상 이미지에서 질환을 찾아낸다. 또 사용자의 성향 데이터를 파악하여 제품을 추천하거나 원하는 상품을 검색해 주고, 반복적인 강화 학습으로 로봇의 움직임을 학습시킬 수 있다. 하지만 간단하고 명확한 규칙으로 해결할 수 있는 문제는 인공지능으로 해결하는 것보다는 전통적인 프로그래밍 방법으로 해결하는 것이 더 효율적이다.

전통적인 프로그램으로 해결하기 어려운 경우 전통적인 방식으로 처리하기에 복잡한 문제이거나 뚜렷한 알고리즘이 없는 경우 그리고 사람이 직접 규칙이나 패턴을 찾기 어려운 문제 등이다.

▲ 기계학습을 이용한 문제 해결 예

활동 조사 탐구

그림을 보고 기계학습이 필요한 경우를 찾아 '○'표를 해 보자.

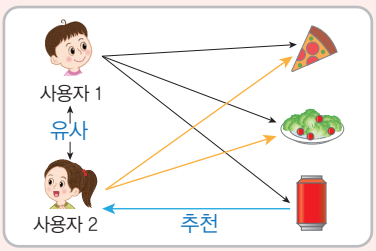

고객의 구매 이력을 활용한 쇼핑 추천

( )

외국어 문장을 사진으로 찍어 바로 번역하기

( )

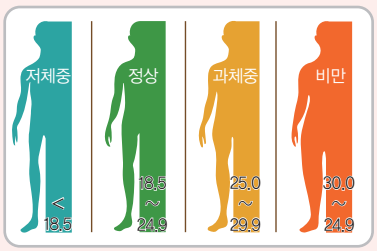

정해진 식에 따른 체질량 지수 구하기

( )

사전 준비하기 오렌지3를 알아볼까요?

오렌지 알아보기 (PDF)

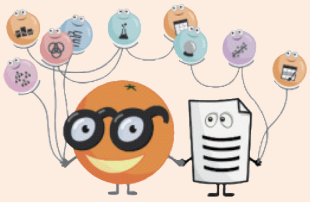

오렌지3(orange3)는 기계학습과 데이터 분석을 위한 오픈 소스 소프트웨어로 슬로베니아 류블랴나 대학교에서 개발하였다. 코드 없이도 통계, 기계학습 및 데이터 시각화 등을 할 수 있는 교육용 프로그램으로 텍스트 코딩 대신 캔버스에 다양한 위젯을 드래그 앤드 드롭(drag and drop)하여 다양한 작업을 할 수 있다.

(1) 프로그램 설치 방법

① 인터넷 검색창에 '오렌지3' 또는 'orange3'를 검색하거나 URL 주소를 입력한다.
[오렌지3 사이트 주소] https://orangedatamining.com/

② [Download] 메뉴에서 자신의 운영체제에 맞는 설치 파일을 다운로드한다.

③ 다운로드한 설치 파일을 [관리자 권한]으로 실행하여 설치한다.

(2) 오렌지3 기본 화면 구성

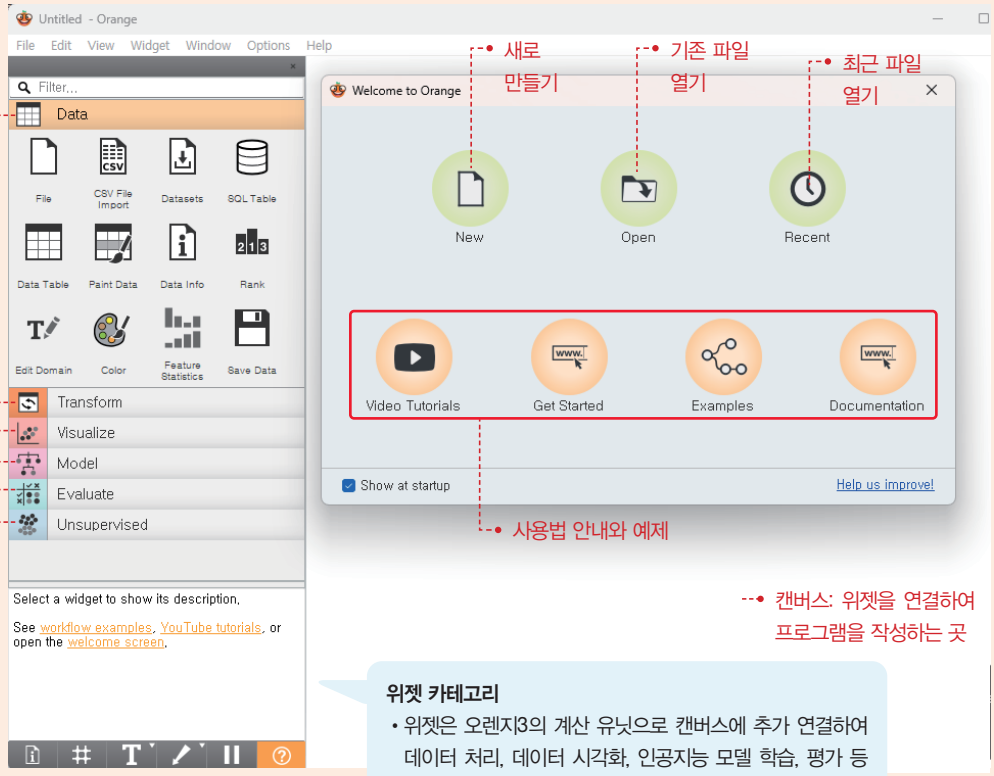

위젯 카테고리

- 위젯은 오렌지3의 계산 유닛으로 캔버스에 추가 연결하여 데이터 처리, 데이터 시각화, 인공지능 모델 학습, 평가 등의 작업을 수행할 수 있다.
- 기본으로 제공되지 않는 위젯은 [Options]–[Add-ons]에서 추가할 수 있다.

(3) 오렌지3 실행하기

① **데이터 준비하기:** [Data] 카테고리의 File 위젯을 캔버스로 드래그하여 가져온 후, File 위젯을 더블 클릭하여 열고 오른쪽 상단의 폴더를 눌러 'iris.tab' 데이터를 불러온다.

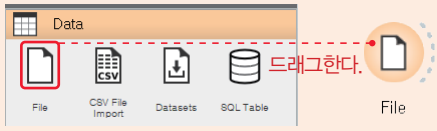

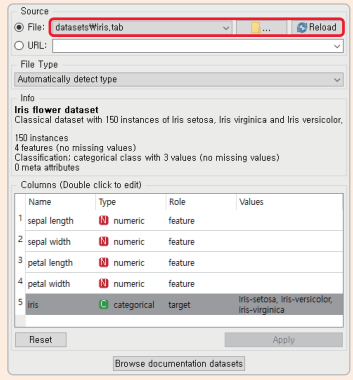

② **데이터 정보 확인하기:** [Data] 카테고리의 Data Table 위젯을 캔버스로 가져와 File 위젯과 마우스로 연결한 후 더블 클릭하여 데이터의 정보를 확인한다.

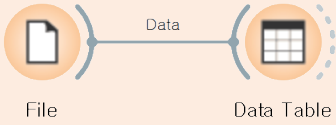

데이터 정보
- 데이터 150개 (결측치 없음.)
- 4개의 속성
- 3 종류의 타깃

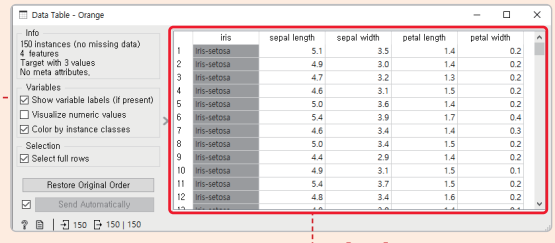

[File] 위젯의 데이터 내용을 확인할 수 있다.

③ **데이터 시각화하기:** [iris] 데이터셋을 산점도로 시각화하여 데이터의 특징을 탐색한다.

❶ [Visualize] 카테고리에서 Scatter Plot 위젯을 가져와 Data Table과 연결한다.

❷ 이때 연결선 위의 글자를 더블 클릭하여 연결선 수정도 가능하다.

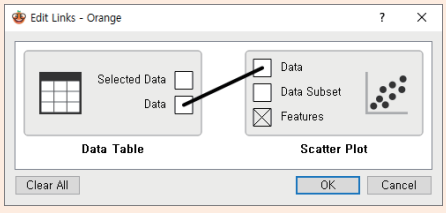

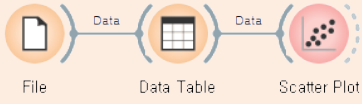

❸ Scatter Plot 위젯을 더블 클릭하여 여러 가지 설정을 변경하며 결과를 확인한다.

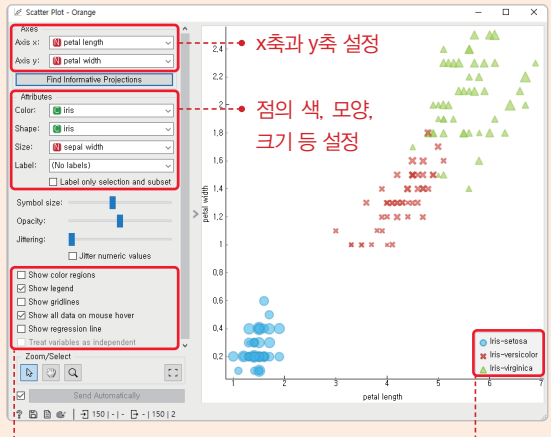

x축과 y축 설정

점의 색, 모양, 크기 등 설정

분포 구역을 색으로 설정, 범례 표시, 격자선 표시, 마우스를 올리면 해당 정보와 회귀선이 표시된다.

범례 설정

분석 x축과 y축을 각각 petal length(꽃잎 길이), petal width(꽃잎 너비)로 설정하였을 때, 산점도 결과를 보면 꽃잎 길이와 꽃잎 너비에 따라 품종이 잘 나뉘어지는 것을 알 수 있다. 꽃잎 길이와 꽃잎 너비가 작은 품종은 setosa, 꽃잎 길이와 꽃잎 너비가 가장 넓은 품종은 virginica라는 것을 알 수 있다.

실습 1 회귀 모델 구현 – 지구 온도 변화 예측하기 융합: 지구 과학

지구 온도 변화 예측하기 (PDF)

문제 상황 2023년 7월 지구 평균 기온이 17℃를 넘어섰다. 기준값은 약 14℃ 정도이고, 종전 최고 기록인 2016년 8월 이후 7년 만에 가장 더운 4일을 기록하였다. 이런 날들이 쌓여 지구 전체의 연평균 기온 상승으로 이어지고 극지방의 얼음층이 녹아내린다.

13 기후변화와 대응

단계 1 문제 정의하기

지난 30년간의 지구 온도 변화 데이터로 앞으로의 지구 온도 변화를 예측하는 기계학습 모델을 만들어 보자.

단계 2 데이터 수집 및 전처리하기

(1) 데이터 수집하기

① 캐글(kaggle) 사이트에서 지구 온도 변화 데이터셋을 다운로드한다.
[데이터 출처] https://www.kaggle.com/datasets/sevgisarac/temperature-change

② 다운로드한 파일에서 'Environment_Temperature_change_E_All_Data_NOFLAG.csv'를 구글 스프레드시트에서 열고 학습에 필요한 형태로 전처리한다. 여기서는 지구 전체의 온도를 대표하기 위해 표준 TMY 기상 데이터값을 사용한다.

표준 TMY 기상 데이터
연간 데이터를 단순히 평균값으로 계산하는 것은 변화의 폭을 과소평가할 수 있다. 이를 위해 특정 위치의 매시간 데이터값을 모은 표준 TMY(Typical Meteorological Year) 기상 데이터셋을 이용한다.

❶ 전체 데이터 중 1행의 헤드 부분과 지구 전체의 표준 TMY 기상 데이터값인 8432행을 선택한 후 Ctrl+C를 눌러 복사한다.

	A	B	C	D	E
8430	5000	World	7019	Sep–Oct–Nov	72
8431	5000	World	7019	Sep–Oct–Nov	60
8432	5000	World	7020	Meteorological y	72

❷ 새 시트에 Ctrl+V를 눌러 붙여넣기한다.

	A	B	C	D	E
1	Area Code	Area	Months Code	Months	Element Code
2	5000	World	7020	Meteorological y	7271

헤드 부분
8432행 내용

❸ ❷에서 만든 내용 중 [H]열(Y1961)부터 [BN]열(Y2019)까지를 복사한다.

	BJ	BK	BL	BM	BN
1	Y2015	Y2016	Y2017	Y2018	Y2019
2	1.419	1.674	1.44	1.301	1.473

❹ 새 시트에서 마우스 오른쪽 버튼을 클릭하여 [선택하여 붙여넣기]–[순서 바꾸기]를 선택하여 행과 열을 바꾼다.

❺ 연도 부분의 'Y'를 없애고 숫자만 남긴다.

	A	B
1	Y1961	0.207
2	Y1962	0.034
3	Y1963	0.159
4	Y1964	-0.253

▲ 표준 TMY 기상 데이터

❻ 'year' 컬럼명과 'temperature' 컬럼명을 지정하고 스프레드시트를 CSV 파일로 저장한다(파일명: Temperature.csv).

year	temperature
1961	0.207
1962	0.034
1963	0.159
1964	-0.253

▲ Temperature.csv

함수로 'Y'글자 없애기
'Y1961'의 오른쪽 4글자(1961)를 right 스프레드 수식을 적용하여 가져올 수 있다.

▶형식 right(문자열 셀 주소, 가져올 개수)

	A	B	C
1	year	temperature	1961
2	Y1961	0.207	=right(A2,4)

새 셀에서 스프레드 수식을 적용한다.

(2) 오렌지에 데이터 불러오기

① 오렌지의 [Data] 카테고리에서 [File]를 선택한다.

② [File]을 더블 클릭하고 준비한 'Temperature.csv' 파일을 불러온다.

③ 화면 아래의 컬럼을 확인하고 예측하는 'temperature' 컬럼을 target으로 지정한다.

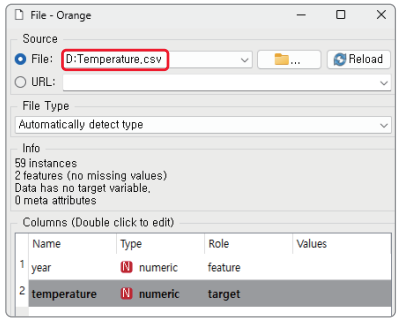

오렌지의 컬럼별 역할(Role)

- feature: 학습에 영향을 주는 값, 특징
- target: 레이블, 타깃
- meta: 학습에 영향은 주지 않지만 참고할 만한 값
- skip: 무시해도 되는 값

year	feature
temperature	target

(3) 데이터셋 확인하기

① [Data] 카테고리에서 [Data Table]을 선택하고, [File]과 [Data Table]을 연결한 후 [Data Table]을 실행한다.

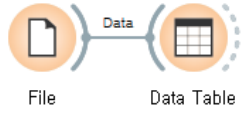

② 데이터셋의 전체적인 정보와 각 데이터값을 확인한다.

전체 59개의 데이터, 1개의 특징이 있음을 알 수 있다.

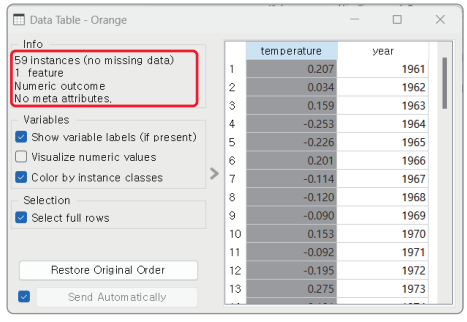

(4) 훈련 데이터와 테스트 데이터 나누기

① [Transform] 카테고리에서 [Data Sampler]를 선택하여 [Data Table]과 연결한다.

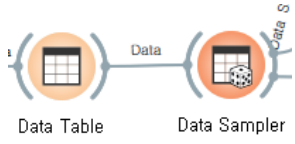

② [Data Sampler]를 실행한다.

③ 훈련 데이터를 전체 데이터의 70%로 지정한다.

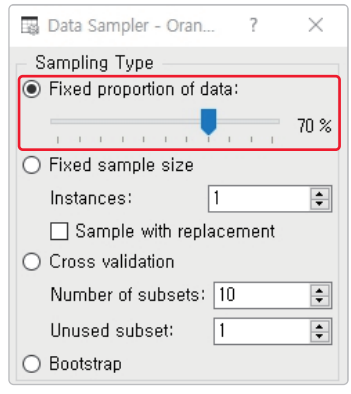

단계 3 모델 선정 및 학습하기

(1) 모델 학습하기

연속되는 수치 데이터값의 변화에 대한 예측이므로 선형 회귀(Linear Regression) 모델을 사용한다.

① [Model] 카테고리에서 [Linear Regression]을 선택한다.

② [Data Sampler]와 [Linear Regression]을 연결한 후 실행한다.

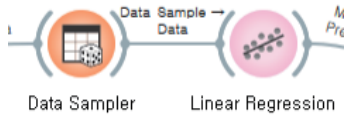

(2) 모델 학습 중의 성능 평가 확인하기

① [Evaluate] 카테고리에서 [Test and Score]를 선택하고 [Linear Regression], [Data Sampler]와 각각 연결한다.

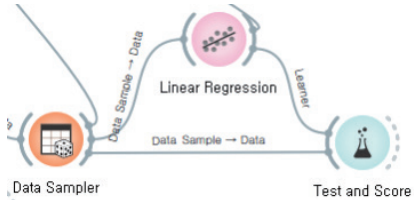

② [Test and Score]를 실행하여 성능 평가 결과를 확인한다.

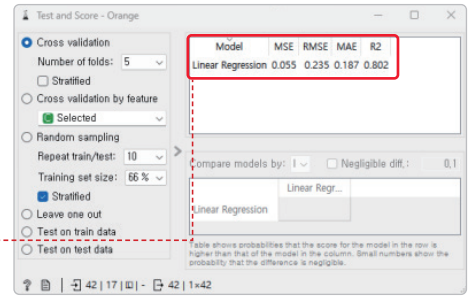

MSE, RMSE, MAE의 값은 작을수록 R2의 값은 1에 가까울수록 성능이 좋다.

여기서 잠깐

회귀 모델 평가 지표

- MSE(Mean Squared Error), RMSE(Root Mean Squared Error), MAE(Mean Absolute Error): 실젯값과 모델이 예측한 예측값과의 차이를 제곱하여 평균을 구하거나 루트 처리한 값으로 작을수록 모델이 우수하다.
- R2(R Squared, 결정계수): 적합한 정도를 재는 척도로 1에 가까울수록 성능이 좋다.

단계 4 모델 평가하기

(1) 모델 성능 평가 및 결과 확인 예측하기

① [Evaluate] 카테고리에서 [Predictions]를 선택하고 [Linear Regression], [Data Sampler]와 각각 연결한다.

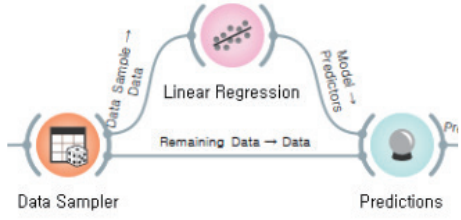

② [Predictions]과 [Data Sampler]의 연결선을 테스트 데이터(Remaining Data) – 데이터(Data)로 연결하여 설정한다.

③ [Predictions]을 실행하여 예측 결과를 확인한다.

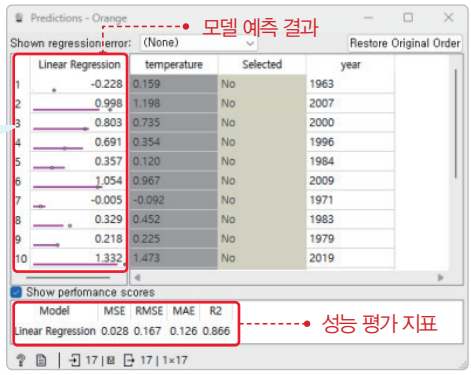

[Linear Regression] 부분의 값이 모델에 의한 예측 결과이다. 이 값과 'temperature' 컬럼값을 비교할 수 있다. 성능 평가 지표의 값으로도 성능 결과를 알 수 있다. 성능 평가 지푯값을 보면 MSE, RMSE, MAE의 값은 작고, R2의 값은 0.866으로 성능이 좋음을 알 수 있다.

(2) 결과 시각화하기

① [Visualize] 카테고리에서 [Scatter Plot]을 선택한 후 [Predictions]과 연결한다.

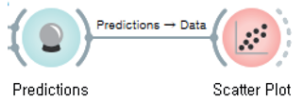

② [Scatter Plot]을 실행하여 데이터의 변화를 산점도 그래프로 확인한다.

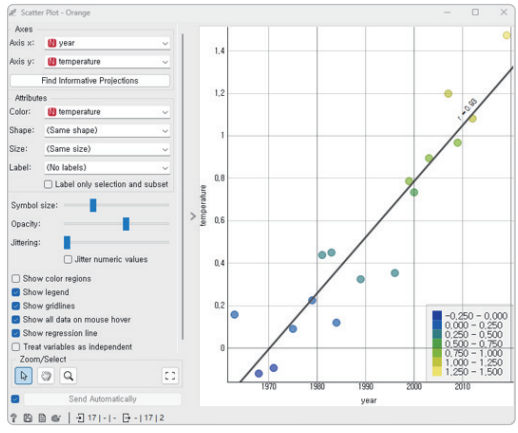

해마다 지구 온도 변화 그래프의 기울기가 상승하고 있어서 앞으로도 지구 온도가 상승할 것으로 예측할 수 있다.

완성

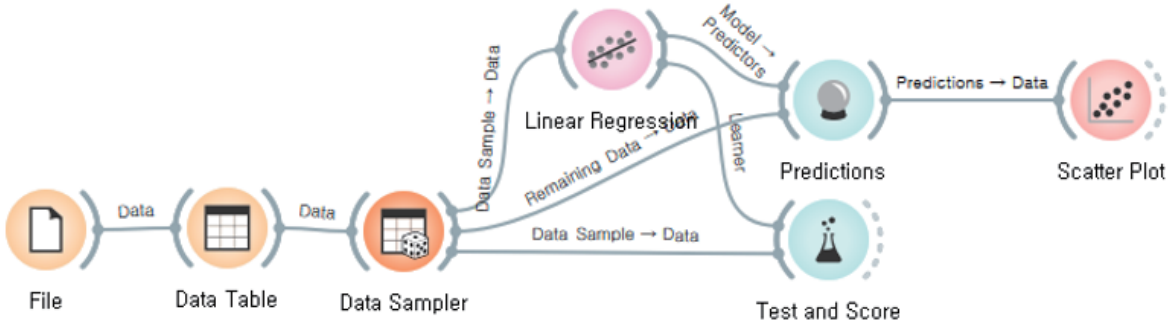

실습 2 분류 모델 구현 – 펭귄 종 분류하기 융합: 생명 과학

펭귄 종 분류하기(PDF)

문제 상황 급격한 기후 변화로 펭귄을 포함한 야생 동물들의 서식지가 위협받고 있다. 펭귄의 활동을 연구하기 위하여 펭귄의 개체 수 추적과 펭귄 종의 표식 구별이 필요하다.

14 해양생태계 보전

단계 1 문제 정의하기

남극에 서식하는 펭귄 세 종류의 부리 길이와 두께, 날개 길이, 몸무게 등의 데이터로 펭귄의 종을 분류하는 기계학습 모델을 만들어 보자.

단계 2 데이터 수집 및 전처리하기

(1) 펭귄 데이터셋 다운로드하기

캐글(kaggle) 사이트에서 아델리펭귄, 턱끈펭귄, 젠투펭귄의 특징이 있는 펭귄 데이터셋을 다운로드한다(파일명: penguins_size.csv).

[데이터 출처] https://www.kaggle.com/datasets/parulpandey/palmer-archipelago-antarctica-penguin-data

▲ 데이터셋에 사용되는 펭귄 세 종류

(2) 오렌지에 데이터 불러오기

① 오렌지의 [Data] 카테고리에서 [File]을 선택한다.

② [File]을 더블 클릭하여 준비한 CSV 파일을 불러온다.

③ 컬럼을 확인하고 예측하려는 펭귄의 종류를 뜻하는 'species' 컬럼만 'target'으로 지정하여 학습 데이터로 설정한다. 서식지인 'island', 성별인 'sex'는 'skip'으로 지정하여 학습 데이터에 포함시키지 않는다.

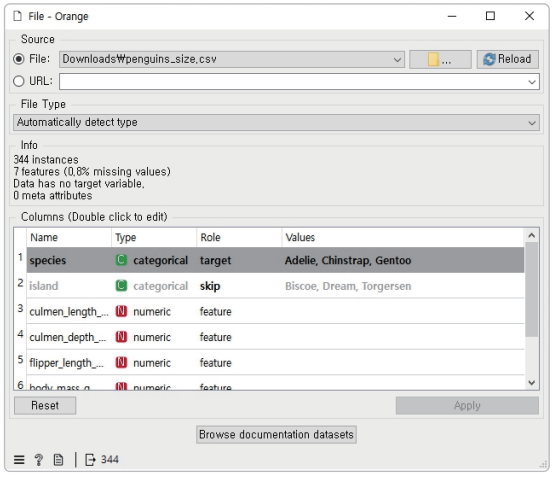

전체 데이터 344개, 타깃 1개, 특징 4개가 있다.

- target
  - species: 펭귄 종(Adelie, Chinstrap, Gentoo)
- feature
  - culmen_length_mm: 부리 길이
  - culmen_depth_mm: 부리 깊이
  - flipper_length_mm: 날개 길이
  - body_mass_g: 몸무게

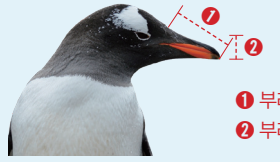

❶ 부리 길이(culmen_length)
❷ 부리 깊이(culmen_depth)

(3) 데이터셋 확인하기

① [Data] 카테고리에서 [Data Table]을 선택한다.
② [File]과 [Data Table]을 연결하고 [Data Table]을 실행한다.
③ 데이터셋의 전체적인 정보와 각 데이터값을 확인할 수 있다.

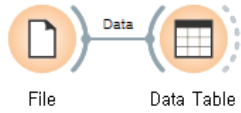

여기서 잠깐

펭귄 데이터는 0.6%의 결측치가 있으므로 결측치가 있는 행은 삭제하여 처리한다.
[File]과 [Transform] 카테고리의 [Preprocess]를 연결하여 결측치를 처리한다.

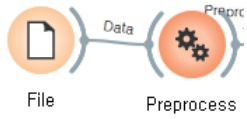

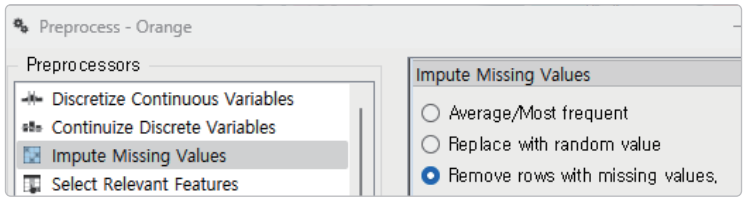

훈련 데이터와 테스트 데이터

Link 185쪽

(4) 훈련 데이터와 테스트 데이터 나누기

① [Transform] 카테고리에서 [Data Sampler]를 선택하여 [Preprocess]와 연결하고 실행한다.

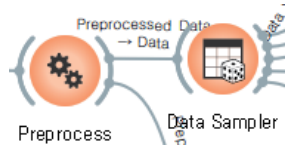

② 훈련 데이터를 전체 데이터의 80%로 지정한다.

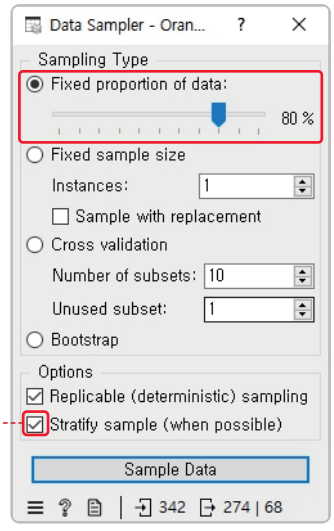

펭귄 종별 데이터의 개수가 같지 않으므로 훈련 데이터와 테스트 데이터를 분할할 때 펭귄 종별 데이터의 비율을 맞추기 위해 체크한다.

단계 3 모델 선정 및 학습하기

펭귄의 종을 분류하기 위하여 k-최근접 이웃, 결정트리, 로지스틱 회귀 알고리즘을 사용한다.

(1) 모델 학습하기

k-최근접 이웃(kNN) 알고리즘

① [Model] 카테고리에서 [kNN]을 선택한다.

② [Data Sampler]와 [kNN]을 연결하고 [kNN]을 실행한다.

③ 알맞은 'Number of neighbors'(이웃의 수)를 정한다(기본값 = 5). 이때 이웃의 수를 여러 값으로 바꿔 가며 예측 결과의 성능 평가 결과가 좋은 모델을 찾을 수 있다.

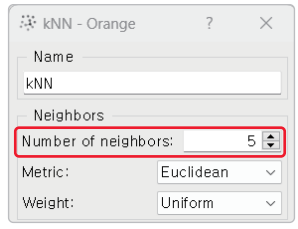

결정트리 알고리즘

① [Model] 카테고리에서 [Tree]를 선택한다.

② [Data Sampler]와 [Tree]를 연결하고 [Tree]를 실행한다.

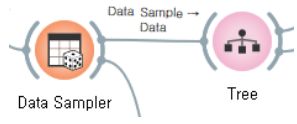

③ 세부 설정값 중 결정트리의 깊이와 크기 등을 조정하며 성능 평가 결과로 좋은 모델을 찾을 수 있다.

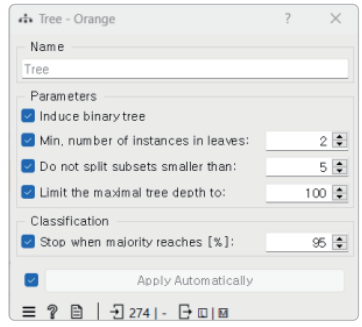

로지스틱 회귀 알고리즘

① [Model] 카테고리에서 [Logistic Regression]을 선택한다.

② [Data Sampler]와 [Logistic Regression]을 연결하고 [Logistic Regression]을 실행한다.

③ 세부 설정값을 수정할 수 있다.

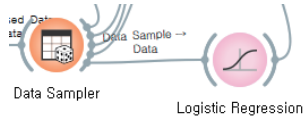

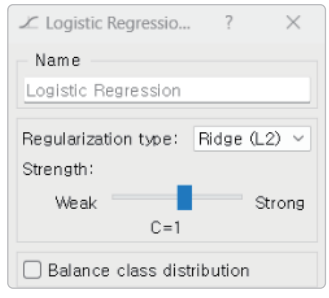

(2) 모델 학습 중의 성능 평가 확인하기

① [Evaluate] 카테고리에서 [Test and Score]를 선택하고 [kNN], [Tree], [Logistic Regression]과 [Data Sampler]와 각각 연결하고 [Test and Score]를 실행한다.

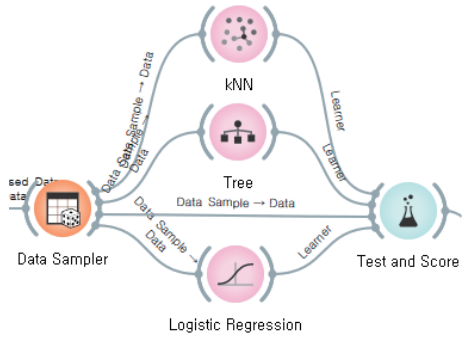

② 성능 평가 결과를 확인한다. 이때 각 모델의 CA값이 1에 가까울수록 성능이 좋다.

CA는 모델이 입력된 데이터를 얼마나 정확하게 분류하는지를 나타내는 분류 정확도이다.

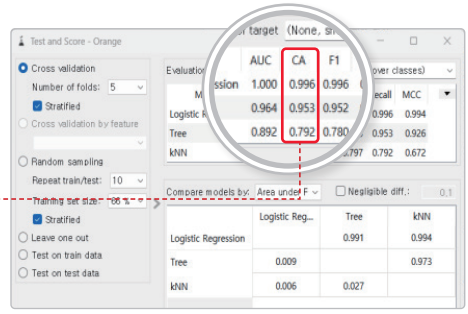

단계 4 모델 평가하기

(1) 모델 성능 및 결과 확인 예측하기

① [Evaluate] 카테고리에서 [Predictions]를 선택하고 [Tree], [kNN], [Logistic Regression], [Data Sampler]와 각각 연결한다.

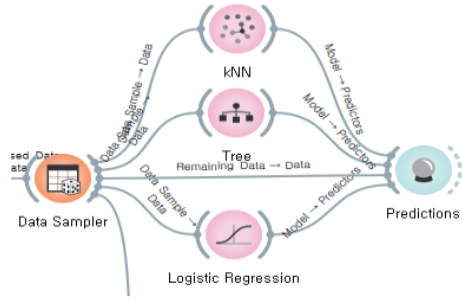

② [Data Sampler]와의 연결선은 [Remaining Data]를 연결한다.

③ [Predictions]를 실행하고 테스트 데이터로 예측한 결과를 확인한다.

성능 평가 지표의 각 모델의 CA값이 1에 가까울수록 성능이 좋은 것이다. 세 가지 모델 중 로지스틱 회귀의 CA값이 0.971로 가장 성능이 좋은 모델임을 알 수 있다.

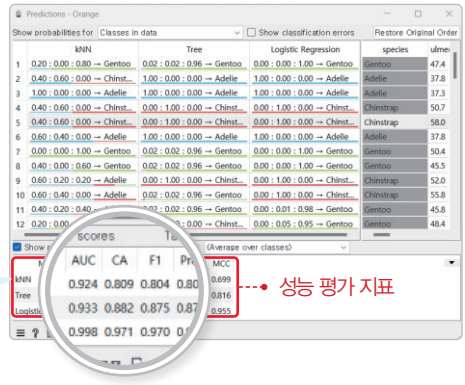

(2) 결과 해석하기

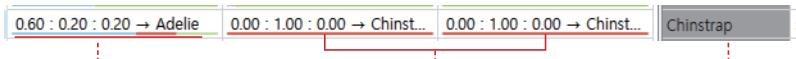

kNN 모델은 아델리펭귄일 확률이 0.6으로 가장 높아 아델리펭귄으로 예측한다.

결정트리 모델과 로지스틱 회귀 모델은 턱끈펭귄일 확률이 가장 높다고 예측한다.

실젯값은 턱끈펭귄이다.

참고 **kNN의 정확도를 높이는 방법**

데이터 간의 거리를 측정하는 kNN 모델은 각 특징값들의 범위와 편차를 일정하게 변환하는 정규화(normalization)를 하면 정확도가 조금 더 높아질 수 있다.

(3) 결정트리 알고리즘 결과 시각화하기

① [Visualize] 카테고리에서 [Tree Viewer]를 선택하고 [Tree]와 연결한다.

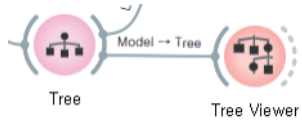

② 분류된 결과를 트리 모양으로 확인할 수 있다.

첫 번째 노드의 특징이 'flipper_length'인 것으로 보아 펭귄의 종을 구분하는 가장 큰 특징은 '날개 길이'임을 알 수 있다.

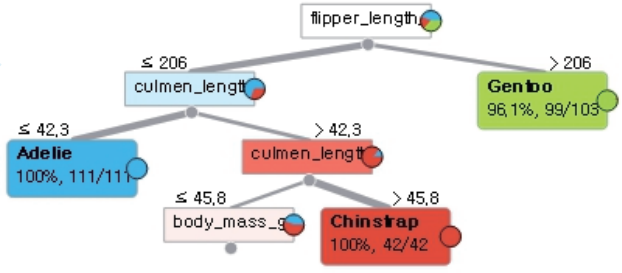
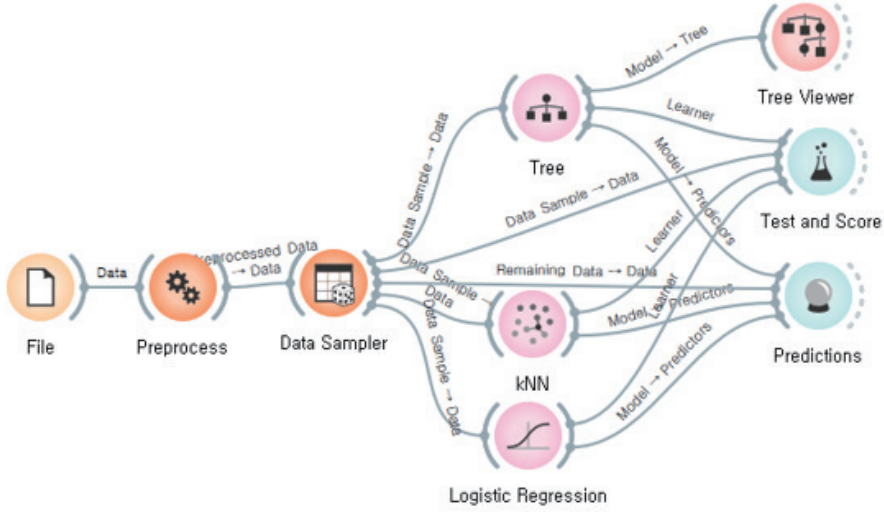
완성